

大模型微调项目第二阶段报告

Raw Data → 指令数据集构建

计算机·密码与安全特化模型

2026 年 7 月 29 日

摘要

本报告记录了第二阶段的核心工作——将第一阶段产出的 19,464 个原始文本块（raw data）通过强模型辅助生成转化为高质量指令微调数据集。采用 DeepSeek- chat 模型作为生成引擎，设计了覆盖五种认知层次的 Prompt 模板，经过 17 批次 API 批量生成、质量过滤和分层抽样，最终产出 3,678 对结构化问答样本，按 80:10:10 划分训练集、验证集和测试集，可直接用于 Qwen3-4B 的 QLoRA 微调训练。

1 阶段概述

1.1 目标

在第一阶段原始文本采集和清洗的基础上，构建面向计算机科学、密码学与网络安全领域的高质量指令微调数据集。主要目标包括：

- 从 raw text chunks 生成多样化问答对
- 覆盖概念解释、章节总结、方法对比、论文摘要理解和推理分析五种任务
- 建立自动质量过滤和人工审核机制
- 按 80:10:10 比例划分训练/验证/测试集
- 产出可直接用于 HuggingFace QLoRA 训练的 JSONL 数据集

1.2 输入与输出

2 Prompt 模板设计

2.1 五种任务类型

根据项目书要求，设计了覆盖不同认知层次的五类任务：

- 概念解释**（目标 30%）——训练模型理解和解释领域核心概念
- 章节总结**（目标 20%）——提升长文本理解和结构化总结能力

表 1: Phase 2输入输出总览		
	描述	数量
输入	Phase 1 raw text chunks	19,464
	实际可用（质量筛选后）	18,597
处理	采样批次数	17
	实际处理 chunks	3,206
	API 生成原始 QA 对	4,199
输出	质量过滤后 QA 对	3,678
	训练集（80%）	2,941
	验证集（10%）	366
	测试集（10%）	371

- 3. **方法对比**（目标 20%）——培养知识迁移和分析比较能力
- 4. **论文摘要理解**（目标 15%）——增强科研文献阅读能力
- 5. **推理分析**（目标 15%）——提高深度分析和安全推理能力

2.2 系统指令

所有 Prompt 共享统一的 System Prompt：

你是一个专业的数据标注助手，负责为计算机科学、密码学和网络安全领域的教材内容生成高质量的训练样本。
你的回答必须是严格的 JSON 格式，不得包含任何 JSON 之外的文字、解释或 markdown 标记。

每条问答对必须：

- 1. 问题有明确的知识目标
- 2. 回答严格依据原文
- 3. 保留原文的专业术语
- 4. 如果原文质量不足以生成有效问答对（例如OCR乱码过多），直接返回空数组 []

2.3 模板示例

概念解释模板——要求生成 2-3 个概念解释类问答对，问题必须针对文本中的具体概念或术语，回答先给定义再展开说明。

方法对比模板——若文本涉及两种以上方法/算法/方案，设计对比问题，涵盖结构、性能、安全性等维度，可用表格呈现。

推理分析模板——问题具有分析深度，要求解释“为什么”或“如何”，回答包含问题分析、原理推导和解决方案。

完整模板定义位于 `phase2/templates/prompts.py`。

3 API 批量生成管道

3.1 架构

Raw Chunk → 质量筛选 → 任务分配 → Prompt构造
→ DeepSeek-Chat API → JSON解析 → 质量验证 → JSONL存储

3.2 强模型选择

采用 DeepSeek-Chat 模型（通过 Anthropic SDK 兼容接口调用）作为生成引擎。选择理由：

- API 兼容 Anthropic Messages 格式，开发成本低
- 中英文双语能力均衡，适合处理混合语料
- 性价比高，支持大规模批量生成

3.3 任务分配策略

采用配额驱动的任务分配算法，确保五种任务类型接近目标比例：

对每个 chunk：

1. 计算当前每种任务的已完成比例
2. 找距离目标比例最远的任务类型
3. 检测 chunk 内容特征（含“比较”→方法对比加成，
含“证明/定理”→推理分析加成，
含“abstract/RFC”→论文摘要加成）
4. 综合选择最优任务类型

3.4 批量处理参数

3.5 错误处理

实现了三级容错机制：

1. **API 瞬时故障**：指数退避重试（1s/2s/4s），最多 3 次
2. **JSON 解析失败**：正则提取 + 回退到单个对象解析
3. **ThinkingBlock 处理**：DeepSeek 推理模型返回的思考块自动过滤，仅保留 TextBlock

整体 API 成功率为 76%（200 chunks 中约 152 个成功），失败主要原因为 chunk 内容过短（<150 字符）或 OCR 乱码严重。

表 2: 批量生成配置

参数	值
模型	deepseek-chat
最大输出 token	2,048
温度	0.7
输入截断	1,500字符
API 调用间隔	2 秒
每 chunk 生成 QA 对数	1-3 对
重试次数	3 (指数退避)
检查点保存间隔	每 20 chunks

4 数据质量控制

4.1 自动过滤规则

1. **长度过滤**: $\text{input} < 5$ 字符或 $\text{output} < 30$ 字符 $\rightarrow$ 丢弃
2. **乱码检测**: 有效字符 (中英文 + 数字 + 标点) 占比 $< 30\%$ $\rightarrow$ 丢弃
3. **输出质量**: $\text{output} < 80$ 字符的浅层回答标记为待审核

4.2 过滤效果

表 3: 质量过滤统计

阶段	数量	说明
API 原始生成	4,199	17 批次全部产出
JSON 解析失败	38	API 返回格式异常
质量过滤剔除	483	短回答/乱码/无意义
最终入库	3,678	通过全部质量检查

5 数据集划分

5.1 分层抽样策略

按 domain (computer_science / crypto_and_security / comprehensive) 进行分层随机抽样, 保证每个子集中领域分布一致。划分比例: 训练集 80%、验证集 10%、测试集 10%。

表 4: 数据集划分结果

领域	总数	训练	验证	测试
crypto_and_security	1,843	1,474	184	185
computer_science	1,708	1,366	170	172
comprehensive	127	101	12	14
总计	3,678	2,941	366	371

表 5: 任务类型分布

任务类型	训练集	验证集	测试集	占比
概念解释	1,455	168	173	49%
推理分析	516	68	62	18%
章节总结	451	65	64	16%
方法对比	336	36	44	11%
论文摘要理解	183	29	28	7%

5.2 输出格式

每条训练样本为标准 instruction-tuning 格式：

```
{
  "instruction": "请解释以下概念\n\n什么是AES加密算法？",
  "output": "AES (Advanced Encryption Standard) 是...",
  "domain": "crypto_and_security",
  "task_type": "概念解释"
}
```

5.3 加载方式

```
from datasets import load_dataset
ds = load_dataset("json", data_files={
    "train": "phase2/dataset/train.jsonl",
    "val":   "phase2/dataset/val.jsonl",
    "test":  "phase2/dataset/test.jsonl",
})
```

表 6: 各子集平均长度

子集	平均 Instruction 长度	平均 Output 长度
训练集	54 字符	252 字符
验证集	53 字符	255 字符
测试集	53 字符	252 字符

6 长度统计

7 项目脚本清单

表 7: Phase 2 脚本文件

文件	功能
templates/prompts.py	5 种任务 Prompt 模板 + System Prompt
scripts/batch_generate.py	API 批量 QA 生成（任务分配/调用/过滤/存储）
scripts/split_dataset.py	分层抽样 + 数据集划分 + HuggingFace 格式导出
scripts/run_all_batches.sh	串行批量执行脚本
scripts/run_remaining.sh	补充批次执行脚本

8 已知局限与改进方向

- 任务分布偏斜**：概念解释占 49%，超出目标 30%。主要原因是早期批次使用随机权重分配，后改为配额驱动的分配器已修复此问题，但前几批数据已生成。
- 输出长度偏短**：平均 output 仅 252 字符。可通过提高 Prompt 要求（“请给出详细回答，不少于 300 字”）来改善。
- 论文摘要理解偏少**（7% vs 目标 15%）：受限于 raw chunks 中论文/标准类内容比例较低。如需补充，可单独从 NIST SP 800 系列和 RFC 文档中生成。
- comprehensive 领域样本不足**（127 对）：该领域本身 chunk 数量有限，跨领域文档仅 126 个。

9 第三阶段展望

第二阶段产出的 phase2/dataset/ 目录可直接迁移至 GPU 设备，进入第三阶段——QLoRA 微调：

- 环境准备：安装 PyTorch、Transformers、PEFT、BitsAndBytes、Accelerate
- 模型加载：Qwen3-4B-Base + 4-bit NF4 量化

3. LoRA 配置: rank=32, alpha=64, target_modules=all-linear
4. 训练参数: batch_size=2, grad_accum=4, lr=2e-4, epochs=3, max_seq_len=1024
5. 预估显存: ~6.1 GB (RTX 4060 8GB 可运行)
6. 评估维度: 准确性、完整性、专业性、忠实性